

PETA JALAN RISET

Infodemiology Kesehatan Indonesia

Framework 8V · Step-by-Step · Panduan Operasional Lengkap

Pendekatan	Infodemiology Study (Multi-Platform)
Data Utama	4 Platform · 11 Tahun · Google Trends + Sosmed
Target Jurnal	Lancet Digital Health · JMIR · BMC Public Health
Framework	8V: Volume · Velocity · Variety · Veracity · Value · Visualization · Vulnerability · Validity

GAMBARAN UMUM 8 FASE KERJA

F1 Fondasi Data	F2 Verifikasi Veracity	F3 Analisis Sentimen	F4 Integrasi Signal	F5 Pemodelan Tren	F6 Visualisasi & Laporan	F7 Etika & Publikasi	F8 Diseminasi & Impact
-----------------------	------------------------------	----------------------------	---------------------------	-------------------------	--------------------------------	----------------------------	------------------------------

1

FONDASI & AUDIT DATA

Volume · Variety · Velocity

1.1 Inventarisasi Dataset

Sebelum analisis apapun, lakukan audit menyeluruh terhadap seluruh dataset yang dimiliki. Dokumentasikan setiap sumber dalam metadata sheet terpusat.

Langkah 1a	Buat spreadsheet 'Dataset_Inventory.xlsx' dengan kolom: Nama_Platform, Rentang_Tahun, Jumlah_Record, Format_File, Tanggal_Scraping, Versi_API.
Langkah 1b	Dokumentasikan 4 platform: Twitter/X, Instagram, YouTube, Google Trends Catat volume per tahun (2013–2023) untuk setiap platform Tandai gap data: bulan/tahun yang data-nya hilang atau tidak lengkap
Langkah 1c	Hitung statistik dasar: total record, distribusi per tahun, distribusi per platform, rasio missing values per kolom utama.
Langkah 1d	Buat Data Quality Report 1-halaman yang akan dilampirkan di Supplementary Material jurnal.

1.2 Standarisasi Format & Preprocessing Awal

Input	Raw files dari 4 platform (JSON / CSV / xlsx)
Proses	Konversi semua timestamp ke UTC+7 (WIB) untuk konsistensi Standarisasi encoding: UTF-8 untuk menangani karakter bahasa Indonesia Buat field baru: year, month, quarter, platform, keyword_category Hapus duplikat berdasarkan post_id + platform
Tools	Python (pandas, pyarrow), R (tidyverse) — pilih satu ekosistem, konsisten
Output	Master file per platform dalam format Parquet atau CSV terkompresi

OUTPUT FASE INI

- ✓ Dataset_Inventory.xlsx — daftar lengkap semua dataset
- ✓ Data_Quality_Report.pdf — ringkasan kualitas data untuk lampiran jurnal
- ✓ Master dataset terstandarisasi per platform (4 file)
- ✓ Dokumentasi preprocessing pipeline (script Python/R)

2

VERIFIKASI VERACITY ← FASE PALING KRITIS

Veracity · Validity

■ **KRITIS:** Ini adalah kelemahan terbesar yang harus diselesaikan sebelum analisis substantif. Jurnal-jurnal Q1 akan menolak tanpa validasi eksternal yang memadai.

2.1 Korelasi dengan Data Riskesdas Kemenkes

Riskesdas 2013, 2018, dan 2023 adalah ground truth resmi pemerintah yang diakui secara internasional. Korelasikan tren diskusi digital Anda dengan prevalensi penyakit di Riskesdas.

Langkah 2a	Unduh data Riskesdas 2013, 2018, 2023 dari situs resmi Kemenkes RI. Fokus pada data prevalensi penyakit tidak menular: DM, hipertensi, obesitas, dll.
Langkah 2b	Buat tabel korelasi: Tahun Riskesdas vs Volume Diskusi Digital Hitung Pearson/Spearman correlation coefficient Visualisasikan dalam scatter plot dengan regression line Interpretasikan apakah pola digital mendahului, mengikuti, atau bersamaan dengan data klinis
Langkah 2c	Jika korelasi signifikan ($r > 0.7$, $p < 0.05$): ini menjadi argumen utama validitas. Jika tidak: diskusikan sebagai keterbatasan dan berikan penjelasan kontekstual.
Pelaporan	Tampilkan dalam tabel: r-value, p-value, 95% CI untuk setiap pasangan variabel

2.2 Anotasi Manual untuk Gold Standard Sentimen

Untuk klaim analisis sentimen yang valid secara akademis, diperlukan inter-rater reliability yang dibuktikan dengan Cohen's Kappa ≥ 0.60 .

Target	300–500 sampel postingan (stratified random sampling: 75–125 per platform)
Tim	Minimum 2 annotator independen. Ideal: 3 annotator (salah satu ahli kesehatan)
Panduan	Buat Annotation Guidelines (5–8 halaman): definisi positif/negatif/netral Sertakan contoh 10+ postingan per kategori dengan rationale Buat form anotasi standar (Google Form atau Excel template)
Proses	Round 1: Setiap annotator anotasi independen tanpa komunikasi Hitung Cohen's Kappa setelah Round 1 Round 2 (jika Kappa < 0.60): diskusi kasus ambiguous, revisi guidelines Final annotation pada seluruh 300–500 sampel
Threshold	Kappa ≥ 0.80 = Excellent 0.60 – 0.79 = Substantial (acceptable) < 0.60 = harus diulang

Output	Gold Standard Dataset: 300–500 postingan berlabel yang menjadi training/validation set
--------	--

OUTPUT FASE INI	
✓	Tabel korelasi Riskesdas vs Digital Trends (dengan r, p-value, CI)
✓	Gold Standard Dataset: 300–500 sampel teranotasi
✓	Annotation Guidelines Document (untuk lampiran jurnal)
✓	Inter-rater Reliability Report: Cohen's Kappa per kategori dan per platform

3

ANALISIS SENTIMEN MULTI-PLATFORM

Value · Validity

3.1 Pemilihan & Konfigurasi Model

Rekomendasi	IndoBERT (model pretrained Bahasa Indonesia) — state-of-the-art untuk konten lokal
Alternatif	VADER + kamus slang Indonesia (lebih cepat, lebih mudah direproduksi) Ensemble: kombinasi IndoBERT + rule-based untuk robustness
Fine-tuning	Gunakan Gold Standard Dataset (Fase 2) sebagai training set (70%) + test set (30%)
Metrik	Accuracy, Precision, Recall, F1-Score per kelas (positif/negatif/netral)
Baseline	Bandingkan model Anda dengan TextBlob atau VADER tanpa fine-tuning sebagai baseline

3.2 Aplikasi pada Dataset Penuh

Input	Master dataset per platform dari Fase 1
Proses	Jalankan model pada seluruh corpus (per platform, per tahun) Simpan skor probabilitas (bukan hanya label) untuk analisis lanjut Agregasi: hitung rata-rata sentimen per bulan/kuartal/tahun
Validasi	Cross-check 50 sampel random hasil model vs anotasi manual — harus $\geq 85\%$ match
Output	Sentiment_Scores.csv: post_id, platform, date, sentiment_label, confidence_score

3.3 Analisis Tren Temporal Sentimen

Tujuan	Identifikasi pergeseran sentimen publik terhadap isu kesehatan selama 11 tahun
Analisis	Plotting tren sentimen bulanan per platform (line chart) Identifikasi titik infleksi (perubahan drastis sentimen) Korelasikan infleksi dengan peristiwa nyata: pandemi, kebijakan, kampanye Kemenkes
Uji Stat	Mann-Kendall Trend Test untuk tren monoton; Breakpoint Analysis (strucchange package R)

OUTPUT FASE INI

- ✓ Model sentimen terlatih + laporan performa (F1, Accuracy, Confusion Matrix)
- ✓ Sentiment_Scores.csv — seluruh corpus berlabel
- ✓ Tren sentimen temporal per platform (visualisasi + data)

✓ Daftar titik infeksi + konteks peristiwa nyata

4

INTEGRASI GOOGLE TRENDS SEBAGAI EXOGENOUS SIGNAL

Variety · Value

■ **KRITIS:** JANGAN perlakukan Google Trends sebagai dokumen teks. Google Trends adalah time-series signal, bukan konten yang bisa dianalisis sentimen.

4.1 Framework Integrasi yang Benar

Google Trends mengukur *search interest* — proxy dari perhatian dan kekhawatiran publik. Ini harus dikorelasikan dengan volume dan sentimen diskusi sosial media, bukan digabungkan secara naif.

Konsep	Google Trends = exogenous variable Volume Sosmed + Sentimen = endogenous variables
Langkah 4a	Unduh data Google Trends per keyword kesehatan (2013–2023) menggunakan pytrends Normalisasi: Google Trends sudah terindeks 0–100; konversi ke z-score untuk komparabilitas Align temporal: samakan granularitas (bulanan) antara Trends dan Sosmed
Langkah 4b	Hitung Granger Causality Test: apakah peningkatan Google Trends <i>mendahului</i> peningkatan diskusi sosial media? (lag 1–3 bulan)
Langkah 4c	Cross-Correlation Function (CCF): identifikasi lag optimal antara dua sinyal Pearson/Spearman correlation: Google Trends vs Volume Posting per bulan Interpretasi: apakah Google Trends berfungsi sebagai 'early warning signal'?
Model	Vector Autoregression (VAR) atau Transfer Function Model untuk pemodelan simultan

OUTPUT FASE INI

- ✓ Google_Trends_Normalized.csv — data terstandarisasi per keyword
- ✓ Granger Causality Test results (tabel dengan F-statistic dan p-value)
- ✓ Cross-Correlation Plot: Google Trends vs Volume Sosmed
- ✓ Narasi: apakah Google Trends berfungsi sebagai leading indicator?

5

PEMODELAN TREN LONGITUDINAL (11 TAHUN)

Velocity · Value · Validity

5.1 Analisis Tren Volume Diskusi

Data	Volume posting per bulan per platform (2013–2023) = 132 titik waktu per platform
Model 1	ARIMA/SARIMA: untuk proyeksi tren dan deteksi seasonality tahunan
Model 2	Prophet (Facebook): sangat baik untuk data dengan holiday effects dan missing data
Model 3	Joinpoint Regression: identifikasi Annual Percent Change (APC) — standar epidemiologi
Interpretasi	Hitung Annual Percent Change (APC) dan Average APC (AAPC) Identifikasi periode dengan pertumbuhan diskusi signifikan Hubungkan dengan event: pandemi COVID-19, program JKN, kampanye GERMAS

5.2 Analisis Perbandingan Antar Platform

Tujuan	Membuktikan bahwa 4 platform merepresentasikan segmen audiens yang berbeda
Metode	ANOVA atau Kruskal-Wallis untuk membandingkan volume antar platform Chi-square untuk membandingkan distribusi sentimen antar platform Pearson correlation matrix: apakah tren antar platform bergerak bersamaan?
Hipotesis	H0: Tidak ada perbedaan signifikan pola diskusi antar platform (tolak jika $p < 0.05$)

5.3 Faktor Penjelas (Covariate Analysis)

Variabel	Event-based dummy variables: pandemi (2020), PSBB, vaksinasi massal Kebijakan kesehatan: pengesahan UU Kesehatan 2023, program Kemenkes Seasonality: bulan Ramadan, hari-hari kesehatan nasional/internasional
Model	Negative Binomial Regression (untuk count data) atau Poisson dengan overdispersion correction

OUTPUT FASE INI

- ✓ ARIMA/Prophet model fit + forecast 2024–2025 (untuk diskusi)
- ✓ Joinpoint Regression output: APC dan AAPC per platform
- ✓ Tabel perbandingan antar platform (statistik inferensial)
- ✓ Interrupted Time Series Analysis untuk dampak COVID-19

6

VISUALISASI & PENULISAN ARTIKEL

Visualization · Value

6.1 Standar Visualisasi Jurnal Q1

Format	Vector format: SVG atau PDF untuk semua figure (bukan JPEG/PNG untuk line art)
Resolusi	Minimum 300 DPI untuk figure yang mengandung foto; 600 DPI untuk line art
Tools	R (ggplot2) atau Python (matplotlib/seaborn) — simpan script untuk reproducibility
Figures Wajib	Figure 1: Flowchart PRISMA-SCR atau CONSORT data collection process Figure 2: Tren volume diskusi 11 tahun per platform (multi-panel) Figure 3: Tren sentimen temporal (stacked area atau line chart) Figure 4: Heatmap korelasi Google Trends vs Sosmed volume Figure 5: Scatter plot korelasi Riskesdas vs Digital Trends

6.2 Struktur Artikel untuk Target Jurnal

Abstract	Background · Methods · Results · Conclusions (max 250–300 kata, structured)
Introduction	Paragraf 1: Burden of disease di Indonesia — kutip Riskesdas + GBD Study Paragraf 2: Peran infodemiology dalam surveilans modern Paragraf 3: Gap penelitian: keterbatasan studi sebelumnya Paragraf 4: Tujuan spesifik studi ini (research objectives)
Methods	Study Design: Infodemiology / Infoveillance Study Data Sources: 4 platform + Google Trends (jelaskan ToS compliance) Data Collection: periode, keywords, kriteria inklusi/eksklusi Sentiment Analysis: model, fine-tuning, validasi (Kappa score) Statistical Analysis: semua uji yang digunakan Ethics Statement: IRB/etika, anonimisasi, persetujuan ToS
Results	Ikuti urutan objectives. Setiap sub-section: satu tabel/figure kunci
Discussion	Interpretasi dalam konteks literatur global Implikasi kebijakan untuk Kemenkes RI Keterbatasan studi (jujur dan sistematis) Arah penelitian selanjutnya
Supplement	Annotation Guidelines, Cohen's Kappa detail, semua script analisis

OUTPUT FASE INI

- ✓ 5+ publication-ready figures (vector format)
- ✓ Draft artikel lengkap sesuai target journal guidelines

✓ Supplementary Materials (annotation guidelines, scripts, tambahan tabel)
✓ Cover letter yang menekankan 11-year longitudinal + 4-platform novelty

7

ETIKA, KEAMANAN DATA & PERSIAPAN PUBLIKASI

Vulnerability · Validity

7.1 Compliance Etika Penelitian

IRB	Ajukan ke Komisi Etik Penelitian Kesehatan institusi Anda. Sertakan dalam submission sebagai 'Ethics Statement' di bagian Methods.
ToS Compliance	Twitter/X Developer Agreement: data hanya untuk non-commercial research Instagram Basic Display API: cantumkan versi API yang digunakan YouTube Data API: sebutkan quota usage dan compliance Google Trends: tidak ada API resmi, gunakan pytrends dengan rate limiting
Anonimisasi	Hapus username, user ID, dan informasi identifikasi dari dataset yang dipublikasi Hash username jika diperlukan untuk tracking longitudinal Jangan cantumkan URL postingan asli dalam paper atau supplementary
GDPR/PDP	Indonesia memiliki UU PDP (2022). Pastikan data collection sebelum 2022 didokumentasikan dengan baik sebagai historical research data.

7.2 Pemilihan Jurnal & Submission Strategy

Jurnal	Impact Factor	Scope Match	Open Access	Prioritas
Lancet Digital Health	~23.8	Sangat Tinggi	Ya (APC)	1
JMIR (Journal of Medical Internet Research)	~7.4	Sangat Tinggi	Ya (APC)	2
BMC Public Health	~4.5	Tinggi	Ya (APC)	3
JMIR Infodemiology	~5.2	Perfect fit	Ya (APC)	2A
PLoS ONE	~3.7	Sedang	Ya (APC)	Backup

* Pertimbangkan JMIR Infodemiology sebagai target utama — jurnal ini *secara spesifik* didedikasikan untuk studi seperti riset Anda dan acceptance rate lebih tinggi.

OUTPUT FASE INI

- ✓ Ethics approval letter dari Komisi Etik
- ✓ Ethics Statement yang siap dimasukkan ke manuscript
- ✓ Anonymized dataset (untuk data sharing requirement jurnal)
- ✓ Target jurnal terseleksi + submission checklist masing-masing jurnal
- ✓ Data Availability Statement

8

DISEMINASI & DAMPAK KEBIJAKAN

Value · Visibility

8.1 Strategi Diseminasi Multi-Level

Akademik	Submit ke jurnal + conference (ISPH, IEA World Congress, atau serupa) Post preprint di medRxiv sebelum atau bersamaan dengan journal submission Daftarkan studi di PROSPERO (jika systematic review component ada)
Kebijakan	Buat policy brief 2-halaman untuk Biro Komunikasi Kemenkes RI Presentasi ke Direktorat Promosi Kesehatan Kemenkes Submit summary ke Puslitbang Kemenkes
Publik	Thread Twitter/X populer tentang temuan kunci (dalam Bahasa Indonesia) Infografis untuk media sosial institusi Press release ke media kesehatan (Detik Health, Kompas Health)
Data Sharing	Deposit anonymized dataset ke Zenodo atau OSF dengan DOI — wajib untuk sebagian besar jurnal Q1

8.2 Roadmap Publikasi (Multi-Paper Strategy)

Paper 1 (Utama)	Longitudinal analysis 11 tahun: volume + sentimen + tren — target JMIR atau BMC
Paper 2 (Metode)	Methodological paper: validasi gold standard annotation untuk Bahasa Indonesia — target JMIR Formative atau J Biomed Inform
Paper 3 (Tematik)	Deep-dive satu topik spesifik (mis. COVID-19 discourse atau DM discourse) — target jurnal tematik yang relevan
Policy Brief	Rekomendasi berbasis bukti untuk Kemenkes: 2–3 halaman, non-teknis, dengan executive summary dan action items

OUTPUT FASE INI

- ✓ Paper 1 submitted ke jurnal target
- ✓ Preprint di medRxiv
- ✓ Policy brief untuk Kemenkes RI
- ✓ Dataset di Zenodo/OSF dengan DOI
- ✓ Infografis hasil penelitian (3–5 visual)

TIMELINE EKSEKUSI & PRIORITAS

Bulan	Fase	Target Deliverable	Prioritas
1–2	F1 + F7	Audit data, inventory, ethics approval	TINGGI
2–3	F2	Anotasi 300–500 sampel + Kappa ≥ 0.60	SANGAT TINGGI
3–4	F3	Model sentimen terlatih + Sentiment_Scores.csv	TINGGI
4–5	F4	Integrasi Google Trends + Granger Test	SEDANG
5–6	F5	Pemodelan tren + Joinpoint Regression	TINGGI
6–7	F6	Draft artikel + semua figures	TINGGI
7–8	F7	Peer review internal + revisi	SEDANG
8–9	F8	Submission ke jurnal target	TINGGI

KEUNGGULAN KOMPETITIF RISET INI: Kombinasi data 11 tahun + 4 platform adalah aset yang sangat langka dalam riset kesehatan digital Indonesia. Frame sebagai *infodemiology study* — pendekatan yang diakui luas di jurnal Lancet Digital Health, JMIR, dan BMC Public Health — sehingga tidak memerlukan data kasus klinis sebagai ground truth. Fokus pada tiga perbaikan kritis: Veracity (korelasi Riskesdas + Cohen's Kappa), Integrasi Google Trends yang benar (exogenous signal), dan Ethics/Vulnerability compliance.

Dokumen ini dibuat sebagai panduan operasional penelitian. Seluruh langkah harus disesuaikan dengan protokol etika institusi dan persyaratan spesifik jurnal yang dipilih.