

Analisis Ekosistem Big Data Akademik Indonesia melalui Semantic Scholar, SINTA, dan Google Scholar sebagai Infrastruktur Strategis Pemetaan Tren Riset Nasional.


Fabio Arayya Pratama | 24083010064 | Big Data D

Tren riset nasional dalam dunia ilmu pengetahuan saat ini sedang berada dalam fase yang menarik sekaligus mengkhawatirkan. Di satu sisi, banyak sekali jumlah karya ilmiah yang dipublikasikan, serta setiap tahunnya terus melonjak drastis. Sebuah tanda bahwa aktivitas riset nasional dalam pendidikan tidak pernah berhenti bergerak maju. Di sisi lain, melimpahnya data publikasi justru menciptakan sebuah tantangan baru, yaitu dengan data penelitian yang tersebar di berbagai platform, kita justru kesulitan melihat gambaran utuh dari lanskap riset nasional. Memang, sejak SINTA hadir di akhir 2016, jumlah publikasi Indonesia yang masuk ke Scopus meroket tajam hingga mengalahkan negara-negara tetangga. Sayangnya, kebanggaan ini menyisakan celah. Pertumbuhan publikasi tersebut mulai melandai sejak 2020, dan tingkat sitasi peneliti kita nyatanya masih sangat tertinggal. Hal ini menjadi bukti nyata bahwa kuantitas jurnal yang banyak belum tentu menghasilkan dampak ilmiah yang kuat. Masalah lainnya terletak pada ekosistem data akademik kita yang ditopang oleh tiga platform besar: SINTA, Semantic Scholar, dan Google Scholar. Ketiganya punya keunggulan masing-masing, namun berjalan sendiri-sendiri tanpa adanya integrasi atau standar data yang seragam. Karena terisolasi, tidak ada satu pun sistem yang bisa memotret riset Indonesia secara menyeluruh. Ujung-ujungnya, para pengambil kebijakan kesulitan merumuskan strategi riset nasional yang akurat.

Dalam menganalisis ekosistem big data akademik, dimensi Volume dan Variety memperlihatkan tumpukan informasi masif yang sayangnya belum terintegrasi dengan baik. Skala literatur ini sangat raksasa, dibuktikan oleh Semantic Scholar yang mengindeks lebih dari 200 juta artikel ilmiah. Di level nasional, kontribusi satu institusi seperti Universitas Indonesia saja mampu menyumbang puluhan ribu dokumen dengan ratusan ribu sitasi di Scopus dan Google Scholar, yang menggambarkan betapa padatnya ekosistem ini (ResearchGateFrontiers). Namun, tantangan terbesarnya justru terletak pada variety atau keberagaman data yang terpecah ke dalam lima lapisan krusial yaitu metadata terstruktur, ekstraksi semantik dari abstrak, jejaring relasi sitasi, metrik performa seperti H-Index, hingga profil afiliasi institusi. Ironisnya, kekayaan data ini terhalang oleh minimnya standarisasi akses lintas platform. Semantic Scholar memang unggul dengan fasilitas API berskema JSON yang rapi, namun SINTA sama sekali tidak menyediakan format ekspor data standar, sementara Google Scholar secara ketat membatasi penarikan data otomatis. Ketimpangan infrastruktur teknis inilah yang pada akhirnya menyulitkan para pengambil kebijakan untuk meramu agregasi data menjadi sebuah wawasan riset nasional yang utuh.

Meninjau dalam aspek Velocity dan Variability kecepatan pembaruan data antarplatform menunjukkan ketimpangan yang cukup ekstrem. Jika sistem otomatis Semantic Scholar mampu memperbarui graf pengetahuannya nyaris seketika, pemutakhiran data SINTA justru berjalan sangat lambat karena bergantung penuh pada inisiatif sinkronisasi manual dari peneliti dan proses verifikasi operator kampus. Alhasil, evaluasi produktivitas riset nasional sering kali berpijak pada data yang sudah usang atau stale data. Di samping itu, dimensi variability memunculkan anomali makna seiring berjalannya waktu. Sebagai contoh, istilah klasifikasi mesin pada publikasi satu dekade lalu kini telah berevolusi maknanya merujuk pada arsitektur pembelajaran mendalam yang jauh lebih kompleks. Tanpa adanya sistem pemrosesan bahasa yang peka terhadap konteks waktu, serta minimnya sistem disambiguasi entitas untuk menyeragamkan puluhan variasi penulisan nama satu kampus, akurasi analisis tren longitudinal akan menjadi sangat bias dan menyesatkan.

Pada akhirnya, fondasi yang paling menentukan keadilan evaluasi akademik bersandar pada Veracity dan Validity, dua dimensi yang saat ini kondisinya paling rentan. Integritas atau veracity data di Google Scholar terbukti sangat mengkhawatirkan. Sebuah studi menemukan tingkat kesalahan sitasi mencapai 99,3% dari ratusan dokumen yang diteliti, belum lagi kerentanannya terhadap praktik manipulasi metrik (MSK Libraryarxiv). Di lingkup domestik, tekanan untuk terus mendongkrak skor publikasi di SINTA justru memicu lonjakan produksi prosiding konferensi yang tidak wajar demi akselerasi karier akademik, sebuah fenomena penyimpangan yang tidak ditemukan di negara tetangga (Sage JournalsTopitalianscientists). Tingkat keabsahan (validity) sistem pemeringkatan nasional juga patut dievaluasi, mengingat riset mendalam membuktikan bahwa enam tingkatan kuartil SINTA secara statistik faktanya hanya terbagi ke dalam empat kelompok yang benar-benar bisa dibedakan secara bermakna (Semantic Scholar). Kendati dihantui oleh berbagai kecacatan struktural ini, Value atau nilai strategis dari ekosistem tersebut sesungguhnya sangat luar biasa jika dibenahi. Optimalisasi infrastruktur lintas platform ini dapat menjadi kunci untuk memetakan lanskap riset nasional secara komprehensif, menemukan celah strategis di kancah riset global, serta mengevaluasi secara pasti seberapa kuat jaringan kolaborasi internasional para peneliti Indonesia.



Gambar 1. Skema Lensa Semantic Scholar, SINTA, dan Google Scholar sebagai Infrastruktur

Usulan pengembangan dengan membangun infrastruktur data lake akademik nasional yang mengintegrasikan data dari SINTA, Semantic Scholar, Google Scholar, bahkan GARUDA dan lain sebagainya seperti repository institusi perguruan tinggi secara terpadu. Berbeda dari sistem agregasi data sederhana, sistem ini dirancang dengan arsitektur medallion berlapis tiga. Lapisan Bronze untuk menyimpan data mentah, lapisan silver untuk proses pembersihan, dan pencocokan identitas, serta lapisan gold yang berisi data terstruktur siap pakai untuk analitik, rekomendasi kebijakan, dan konsumsi publik. Sebagai upaya menekan praktik manipulasi sitasi, SINTA perlu mengintegrasikan modul analitik jaringan otomatis berbasis algoritma deteksi komunitas, seperti metode Louvain. Sistem ini bekerja dengan mendeteksi anomali pada kelompok peneliti yang saling mengutip naskahnya sendiri secara berlebihan. Alih-alih bertindak sebagai instrumen penghukum, teknologi ini lebih ideal difungsikan sebagai sistem peringatan dini (early warning) untuk membantu proses verifikasi lanjutan oleh kurator manusia. Pendekatan struktural ini jauh lebih efektif dalam membongkar pola manipulasi yang terorganisir dibandingkan sekadar memantau batas kewajaran metrik pada masing-masing individu.

Referensi:

Ansar, F., Ibrahim, C., Jaya, A., Fadhli, R., & Umasugi, M. (2024). Evaluating the efficiency of Indonesian library and information science journals: A data envelopment and bibliometric analysis. *Khazanah al-Hikmah: Jurnal Ilmu Perpustakaan, Informasi, & Kearsipan*, 12(1).

Aria, M., & Cuccurullo, C. (2023). openalexR: An R-tool for collecting bibliometric data from OpenAlex. *The R Journal*, 15(4). <https://doi.org/10.32614/RJ-2023-089>

Cahya, E. (2025). An examination of the Indonesian journal ranking system. *ResearchGate Preprint*. <https://www.researchgate.net/publication/388830969>

IAES Journal. (2024). Science and Technology Index (SINTA): An overview. *IAES International Journal of Informatics and Technology*. <https://www.iaesjournal.com/science-and-technology-index-sinta-an-overview/>

López-Cózar, E. D., Robinson-García, N., & Torres-Salinas, D. (2014). The Google Scholar experiment: How to index false papers and manipulate bibliometric indicators. *Journal of the Association for Information Science and Technology*, 65(3), 446–454.

Wahyudi, R., & Berlilana, B. (2022). Utilization of SINTA (Science and Technology Index) as web-based research information systems and technology performance measurement. *Journal on Education*, 4(2).